

Clustering à base de densité

1

NECIR HAMID


HAMID NECIR | COURS FOUILLE DE DONNÉES

Motivation

2

NECIR HAMID

- k-means forme nécessairement des clusters convexes, ce qui n'est pas le cas de ce genre de figure. Par exemple, sur l'image ci-dessous, un segment reliant un point en haut du cercle extérieur à un point en bas du même cercle pourra contenir des points des deux autres cercles/clusters).



Notion de Cluster basée sur la densité

3

NECIR HAMID



- ▶ On détecte facilement les points qui appartiennent à un cluster et ceux qui n'appartiennent à aucun et sont non significatifs (on parle de bruit).
- ▶ En effet à l'extérieur des clusters la densité des zones de bruit est inférieure à celle de chacun des clusters.

Principe

4

NECIR HAMID

- Ce type de clustering se base sur l'utilisation de la densité à la place de la distance.

On dit qu'un point est dense si le nombre de ses voisins dépasse un certain seuil. Un point est voisin d'un autre point s'il est à une distance inférieure à une valeur fixée R .



Algorithme DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

5

NECIR HAMID

L'algorithme DBSCAN utilise 2 paramètres :


R: la distance R(rayon de voisinage)

MinP : le nombre minimum de points (voisins) devant se trouver dans un rayon R pour que ces points soient considérés comme un cluster

Exemple :

R=2 unités

MinP=4




Fonctionnement de l'algorithme DBSCAN

6

Un point est voisin d'un autre point s'il est à une distance inférieure à une valeur fixée R .

Chaque point peut être considéré comme :


- **Point central:** Un point est central s'il a au moins MinP points dans son voisinage formé par un cercle de rayon R .



Fonctionnement de l'algorithme DBSCAN

7

- **Point bordure** : Un point est bordure s'il a moins de MinP points dans son voisinage R mais il est dans le voisinage d'un point central




Fonctionnement de l'algorithme DBSCAN

8

Point aberrant (bruit) : Un point est du bruit s'il n'est ni central ni bordure

$R = 1$
 $\text{MinP} = 5$




Illustration

9

NECIR HAMID

$R = 1$
 $\text{MinP} = 5$



Principes

10

- ▶ Deux points centraux qui sont à moins de R unités l'un de l'autre sont dans le même cluster
- ▶ Tout point central qui est dans le voisinage d'un point central appartient au même cluster que lui
- ▶ Le bruit n'est pas considéré

Fonctionnement de DBSCAN :

11

NECIR HAMID

1. DBSCAN commence par un point de données de départ arbitraire qui n'a pas été visité.
2. Le voisinage de ce point est extrait en utilisant une distance R .

2- Si nombre de points $\geq \text{MinP}$) dans ce voisinage Alors
le point de données actuel devient le premier point du nouveau cluster.

■ Sinon le point sera étiqueté comme bruit.

■

Dans les deux cas, ce point est marqué comme «visité».

– Pour ce nouveau cluster, les points situés dans son voisinage à distance R se joignent également au même cluster.

Cette procédure est ensuite répétée pour tous les nouveaux points qui viennent d'être ajoutés au groupe de cluster.

Fonctionnement de DBSCAN :

12

NECIR HAMID

- ▶ 4 – Ainsi le processus des étapes 2 et 3 est répété jusqu'à ce que tous les points à proximité du R voisinage du cluster ont été visités et étiquetés.

5 – Une fois terminé avec le cluster actuel, un nouveau point non visité est récupéré et traité, ce qui permet de découvrir un nouveau cluster ou du bruit.

- ▶ Ce processus se répète jusqu'à ce que tous les points soient marqués comme étant visités.
- ▶ A la fin, chaque points a été marqué comme appartenant à un cluster ou comme étant du bruit.

Avantages

13

NECIR HAMID

- ▶ L'algorithme est très simple et ne nécessite pas qu'on lui précise le nombre de clusters à trouver.
- ▶ Il est capable de gérer les données aberrantes en les éliminant du processus de partitionnement.
- ▶ Les clusters peuvent être de forme différentes et n'ont pas pour obligation d'être linéairement séparables.
- ▶ Cependant, il n'est pas capable de gérer des clusters de densités différentes.

Inconvénients

14

- ▶ Il n'est pas capable de gérer des clusters de densités différentes.
- ▶ Les résultats dépendant de la valeur R et $MinP$

Exercice

► $R=1.9$ $\text{MinP}=4$

15

NECIR HAMID

Point	X	Y
P1	3	7
P2	4	6
P3	5	5
P4	6	4
P5	7	3
P6	6	2
P7	7	2
P8	8	4
P9	3	3
P10	2	6
P11	3	5
P12	2	4

Exercice 2

► R=1.9 MinP=4

P1	0.00											
P2	1.41	0.00										
P3	2.83	1.41	0.00									
P4	4.24	2.83	1.41	0.00								
P5	5.66	4.24	2.83	1.41	0.00							
P6	5.83	4.47	3.16	2.00	1.41	0.00						
P7	6.40	5.00	3.61	2.24	1.00	1.00	0.00					
P8	5.83	4.47	3.16	2.00	1.41	2.83	2.24	0.00				
P9	4.00	3.16	2.83	3.16	4.00	3.16	4.12	5.10	0.00			
P10	1.41	2.00	3.16	4.47	5.83	5.66	6.40	6.32	3.16	0.00		
P11	2.00	1.41	2.00	3.16	4.47	4.24	5.00	5.10	2.00	1.41	0.00	
P12	3.16	2.83	3.16	4.00	5.10	4.47	5.39	6.00	1.41	2.00	1.41	0.00
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12

Point	X	Y
P1	3	7
P2	4	6
P3	5	5
P4	6	4
P5	7	3
P6	6	2
P7	7	2
P8	8	4
P9	3	3
P10	2	6
P11	3	5
P12	2	4

► Distance euclidienne

Exercice 2

► R=1.9 MinP=4

17

NECIR HAMID

P1	0.00											
P2	1.41	0.00										
P3	2.83	1.41	0.00									
P4	4.24	2.83	1.41	0.00								
P5	5.66	4.24	2.83	1.41	0.00							
P6	5.83	4.47	3.16	2.00	1.41	0.00						
P7	6.40	5.00	3.61	2.24	1.00	1.00	0.00					
P8	5.83	4.47	3.16	2.00	1.41	2.83	2.24	0.00				
P9	4.00	3.16	2.83	3.16	4.00	3.16	4.12	5.10	0.00			
P10	1.41	2.00	3.16	4.47	5.83	5.66	6.40	6.32	3.16	0.00		
P11	2.00	1.41	2.00	3.16	4.47	4.24	5.00	5.10	2.00	1.41	0.00	
P12	3.16	2.83	3.16	4.00	5.10	4.47	5.39	6.00	1.41	2.00	1.41	0.00
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12

P1: P2, P10	P2: P1, P3, P11	P3: P2, P4	P4: P3, P5
P5: P4, P6, P7, P8	P6: P5, P7	P7: P5, P6	P8: P5
P9: P12	P10: P1, P11	P11: P2, P10, P12	P12: P9, P11

Exercice 2

► R=1.9 MinP=4

18

NECIR HAMID

Point	Status	
P1	Noise	Bordure
P2	Central	
P3	Noise	Bordure
P4	Noise	Bordure
P5	Central	
P6	Noise	Bordure
P7	Noise	Bordure
P8	Noise	Bordure
P9	Noise	
P10	Noise	Bordure
P11	Central	
P12	Noise	Bordure

P1:P2,P10	
P5:P4,P6,P7,P8	
P9:P12	
P2:P1, P3, P11	
P6:P5, P7	
P10:P1, P11	
P3:P2, P4	P4:P3, P5
P7:P5, P6	P8:P5
P11:P2,P10,P12	P12:P9, P11